Université Lumière Lyon 2

Apache Hop

Présentation générale et découverte de la plateforme d'orchestration

Abdoul Faisal Ouedraogo Thomas Fonferrier Amirat Meroua

Plan de la présentation

01

Généralités ETL

Définition, types et acteurs clés du marché.

02

Apache Hop

Introduction, philosophie et architecture globale.

03

Concepts & Pratique

Pipelines, workflows et mise en œuvre technique.

Qu'est-ce qu'un ETL ?

Processus fondamentaux pour extraire, transformer et charger des données hétérogènes.

Extract

Extraction des données à partir de plusieurs sources.

Transform

Nettoyage, reformatage et enrichissement des données.

Load

Chargement des données traitées dans la destination cible.

Types d'ETL existants

Via du Code

- Liberté totale de conception
- Utilisation de procédures stockées
- Maintenance et compétences avancées requises

ELT & ETL Classique

- Interfaces pour la maintenance
- Serveur d'ETL indépendant ou SGBD
- Outils dédiés (Talend, Pentaho, etc.)

Quelques ETL du marché

Open Source

Talend, Pentaho, Apache Hop, Apache NiFi.

Incontournables

Informatica, DataStage.

Divers / Éditeurs

Sunopsis (ODI), Microsoft SQL Server Integration Services.

Apache Hop

Hop Orchestration Platform : une plateforme d'intégration de données open source.

Qu'est-ce que c'est ?

Fonctionnalités puissantes pour l'ETL, la gestion des workflows et des métadonnées.

Premiers pas

Disponible sur hop.apache.org. Interface graphique conviviale pour démarrer.

Objectifs et Philosophie

Simplification

Simplifier l'orchestration des données et des métadonnées.

Accessibilité

Les tâches simples sont faciles, les tâches complexes sont possibles.

Conception Visuelle

Approche centrée sur les objectifs plutôt que sur le code brut.

Architecture d'Apache Hop

Moteur Hop

Au cœur de Hop se trouve un moteur compact, puissant et flexible.

Plugins

Environ 400 plugins pour étendre et personnaliser facilement les fonctionnalités.

Adaptabilité

Conçu pour IoT, gros volumes, local, cloud, conteneurs et Kubernetes.

Runtimes Flexibles

Développement Visuel

Création des workflows et pipelines dans Hop GUI.

Moteurs d'Exécution

Exécution native (locale/distance) ou via Apache Beam (Spark, Flink, Dataflow).

Cas d'utilisation principaux

Grandes Données

Chargement via environnements parallèles.

Entrepôt de Données

Support SCD et clés de substitution.

Intégration NoSQL

Combinaison relationnel et NoSQL.

Migration & Profilage

Analyse, purification et migration.

Concepts Fondamentaux

Métadonnée

Au cœur de Hop, base de toutes interactions et définitions.

Pipelines

Collections de transformations s'exécutant en parallèle.

Workflows

Séquences d'actions exécutées de manière séquentielle.

Pipeline ou Workflow ?

Pipeline

- Travail concret sur les données
- Transformations en parallèle
- Ex: Lire un CSV, écrire en base

Workflow

- Orchestration des actions
- Enchaînement selon succès/échec
- Ex: Lancer un pipeline, archiver

Briques de base

Action	Opération d'un workflow qui renvoie un statut (vrai/faux) influençant la suite.
Hop	Lien entre deux actions ou transformations (porte un statut ou des données).
Transformation	Unité de travail d'un pipeline (lecture, jointure, enrichissement, nettoyage).

Modèle Mental : Le DAG

Directed Acyclic Graph : un flux sans boucles.



Projets et Environnements

Projet

Regroupe configurations, variables, métadonnées, pipelines et workflows.

Environnement

Définit la config réelle d'exécution (dev, uat, prd) : connexions, chemins, secrets.

Premiers pas : Installation

1. Télécharger une distribution officielle depuis le site du projet.
2. Installer un JDK compatible (notamment Java 11).
3. Décompresser Hop dans le dossier de son choix.
4. Lancer Hop GUI via le script fourni.

Construire un Pipeline

1. Création

Nouveau pipeline depuis la barre d'outils ou Fichier.

2. Ajout

Placer les transformations nécessaires dans le canevas.

3. Connexion

Relier les éléments à l'aide des Hops.

Méthodes de création d'un Hop

Shift-drag

Maintenir Shift, cliquer sur une transformation et glisser vers la seconde.

Scroll-drag

Utiliser le bouton central de la souris pour relier deux éléments.

Menu contextuel

Ouvrir la boîte de dialogue et choisir "Créer un saut".

Bonnes Pratiques

Garantir la maintenabilité et la robustesse des flux.

- Nommer clairement pipelines et workflows
- Séparer dev, recette et production
- Centraliser les paramètres

- Versionner les artefacts Hop
- Documenter sources et sorties
- Prévoir logs et reprise sur erreur

Merci !

Des questions sur vos flux de données avec Apache Hop ?