

Travaux Dirigés – Apache Hop

Data Engineering et préparation de données

Master 2 – Data Science

Construire un pipeline ETL complet avec Apache Hop

Durée : 1 heure
Outil : Apache Hop
Données : clients.csv, produits.csv, commandes.csv
Niveau : M2 Data Science

Objectif : construire un pipeline de préparation et d'analyse de données de bout en bout avec Apache Hop.

1 Contexte

Vous travaillez comme **data engineer** pour une entreprise de commerce en ligne.

Plusieurs systèmes produisent quotidiennement des données concernant les clients, les produits et les commandes.

Ces données sont stockées dans trois fichiers CSV indépendants :

- `clients.csv`
- `produits.csv`
- `commandes.csv`

Le service décisionnel souhaite obtenir des indicateurs permettant d'analyser les ventes.


Cependant, les données brutes contiennent volontairement plusieurs problèmes :

- valeurs manquantes ;
- doublons ;
- identifiants inexistantes ;
- quantités invalides ;
- dates incorrectes ;
- données incohérentes.

Votre objectif est donc de construire avec Apache Hop un pipeline permettant de transformer ces données brutes en données exploitables.

2 Objectif du TD

À la fin du TD, vous devrez avoir construit un traitement semblable à celui-ci :



Vous utiliserez également un **Workflow Apache Hop** afin d'orchestrer les différentes étapes du traitement.

3 Structure des données

3.1 clients.csv

Le fichier contient notamment :

Champ	Type	Description
client_id	entier	Identifiant du client
nom	texte	Nom du client
email	texte	Adresse email
ville	texte	Ville du client
date_inscription	date	Date d'inscription

3.2 produits.csv

Champ	Type	Description
produit_id	entier	Identifiant du produit
produit	texte	Nom du produit
categorie	texte	Catégorie du produit
prix	réel	Prix unitaire

3.3 commandes.csv

Champ	Type	Description
commande_id	entier	Identifiant de la commande
client_id	entier	Client ayant effectué la commande
produit_id	entier	Produit commandé
date	date	Date de la commande
quantite	entier	Quantité commandée

4 Organisation du TD

Le TD est divisé en cinq étapes :

Étape	Objectif	Temps
1	Prise en main et import des données	10 min
2	Nettoyage des données	10 min
3	Jointure et calcul du CA	15 min
4	Agrégations et export	10 min
5	Workflow et défi final	15 min

Attention

Le but n'est pas de reproduire mécaniquement un pipeline montré pendant le cours. Vous devez comprendre le rôle de chaque transformation et être capable d'expliquer pourquoi elle est utilisée.

5 Étape 1 – Prise en main et import des données

Temps conseillé : 10 minutes

5.1 Création du projet

Créez un nouveau projet Apache Hop.

Vous pouvez par exemple utiliser :

```
Nom du projet : ecommerce_td
```

Organisez vos fichiers de manière similaire à :

```
ecommerce_td/  
|  
+-- data/  
| +-- clients.csv  
| +-- produits.csv  
| +-- commandes.csv  
|  
+-- pipelines/  
|  
+-- workflows/
```

5.2 Première question

Avant de construire le pipeline, observez les trois fichiers.

Question 1 :

Quel fichier doit être considéré comme la table centrale de notre analyse des ventes ?
Pourquoi ?

5.3 Lecture du fichier commandes.csv

Créez un premier **Pipeline**.

Ajoutez une transformation permettant de lire le fichier :

```
commandes.csv
```

Vérifiez que les champs suivants sont correctement détectés :

- commande_id ;
- client_id ;
- produit_id ;
- date ;
- quantite.

Ajoutez ensuite une transformation permettant de visualiser ou d'inspecter les données.

Question 2 :

Combien de lignes contient le fichier commandes.csv ?

Question 3 :

Quels problèmes de qualité des données pouvez-vous déjà observer ?

6 Étape 2 – Nettoyage des données

Temps conseillé : 10 minutes

Les données fournies contiennent volontairement des anomalies.

Votre objectif est de produire un jeu de données suffisamment propre pour effectuer les jointures et calculer le chiffre d'affaires.

6.1 Nettoyage des commandes

Vous devez notamment identifier les commandes ayant :

- une quantité égale à zéro ;
- une quantité négative ;
- une quantité anormalement élevée ;
- une date invalide.

Utilisez les transformations Apache Hop adaptées.

Mission

Conservez uniquement les commandes considérées comme valides.

Pour cet exercice, une commande valide possède :

- une quantité strictement positive ;
- une quantité inférieure ou égale à 20 ;
- une date valide.

6.2 Nettoyage des clients

Identifiez les problèmes présents dans `clients.csv`.

Vous devez notamment traiter :

- les villes manquantes ;
- les doublons ;
- les emails manquants.

Question 4 :

Quelle stratégie avez-vous utilisée pour traiter les villes manquantes ?

Question 5 :

Pourquoi est-il important de supprimer les doublons avant certaines jointures ?

6.3 Nettoyage des produits

Identifiez les produits dont le prix est manquant.

Pour simplifier le TD, vous pouvez supprimer les produits dont le prix n'est pas disponible.

Attention

Attention : supprimer une ligne n'est pas toujours la meilleure solution dans un projet réel. Le choix dépend du contexte métier et de l'importance de la donnée supprimée.

7 Étape 3 – Jointures et calcul du chiffre d'affaires

Temps conseillé : 15 minutes

Vous disposez maintenant de données nettoyées.

Votre objectif est de construire un dataset enrichi contenant les informations suivantes :

```
commande_id
client_id
nom
ville
produit_id
produit
categorie
prix
quantite
date
```

7.1 Jointure avec les clients

À partir des commandes nettoyées, réalisez une jointure avec `clients.csv`.

La clé de jointure est :

$$commandes.client_id = clients.client_id \quad (1)$$

Vous devez récupérer au minimum :

- le nom du client ;
- la ville du client.

7.2 Jointure avec les produits

Ajoutez maintenant les informations provenant de `produits.csv`.

La clé de jointure est :

$$commandes.produit_id = produits.produit_id \quad (2)$$

Vous devez récupérer :

- le nom du produit ;
- la catégorie ;
- le prix.

7.3 Dataset enrichi

Vous devez maintenant obtenir une structure similaire à :

ID commande	Client	Ville	Produit	Catégorie	Prix	Qté	Date
...	...	...	...	...	...	...	...

Question 6 :

Pourquoi les commandes constituent-elles la table centrale de cette analyse ?

7.4 Calcul du chiffre d'affaires

Ajoutez maintenant une transformation permettant de calculer une nouvelle colonne :

$$CA = \text{prix} \times \text{quantité} \quad (3)$$

La nouvelle colonne doit s'appeler :

ca

Vérifiez manuellement quelques lignes afin de vous assurer que le calcul est correct.

8 Étape 4 – Agrégation et production des résultats

Temps conseillé : 10 minutes

Le service décisionnel souhaite obtenir trois analyses.

8.1 CA par client

Construisez un traitement permettant de calculer :

$$CA_{client} = \sum CA \quad (4)$$

Le résultat doit contenir au minimum :

```
client_id
nom
ville
CA_total
```

Exportez le résultat dans :

resultats_ca_client.csv

8.2 CA par produit

Construisez une seconde agrégation permettant d'obtenir :

```
produit_id  
produit  
categorie  
CA_total
```

Exportez le résultat dans :

```
resultats_ca_produit.csv
```

8.3 CA par ville

Construisez enfin une agrégation permettant d'obtenir :

```
ville  
CA_total
```

Exportez le résultat dans :

```
resultats_ca_ville.csv
```

Conseil

Vous pouvez créer plusieurs pipelines séparés pour les trois analyses, ou réfléchir à une organisation plus élégante. L'objectif est de privilégier une architecture compréhensible et réutilisable.


9 Étape 5 – Orchestration avec un Workflow

Temps conseillé : 10 minutes

Vous disposez maintenant de plusieurs pipelines.

Votre objectif est de les orchestrer à l'aide d'un **Workflow Apache Hop**.

Le workflow doit avoir une structure similaire à :



9.1 Objectif

Lorsque vous lancez le workflow, vous devez être capable d'obtenir automatiquement les trois fichiers :

```
resultats_ca_client.csv  
resultats_ca_produit.csv  
resultats_ca_ville.csv
```

sans devoir lancer manuellement chaque pipeline.

9.2 Gestion des erreurs

Ajoutez si possible une gestion permettant d'identifier l'échec d'une étape.

Réfléchissez à la question suivante :

Que doit-il se passer si le pipeline de nettoyage échoue ? Les étapes suivantes doivent-elles être exécutées ?

10 Défi final – 5 minutes

Mission

Le service marketing souhaite maintenant identifier les ventes importantes.
Ajoutez une nouvelle colonne :

$$\text{segment} = \begin{cases} \text{Premium} & \text{si } CA \geq 100 \\ \text{Standard} & \text{sinon} \end{cases} \quad (5)$$

Vous devez intégrer cette information dans votre pipeline.

Objectif :

Le résultat final doit contenir au minimum :

```
commande_id
client_id
nom
ville
produit_id
produit
categorie
prix
quantite
date
ca
segment
```

Question finale :

Quelle transformation Apache Hop avez-vous utilisée pour réaliser cette classification ?

11 Questions de synthèse

Répondez brièvement aux questions suivantes.

1. Quelle est la différence entre un **Pipeline** et un **Workflow** dans Apache Hop ?
2. Pourquoi les données doivent-elles être nettoyées avant les jointures ?
3. Quelle est la clé permettant de relier les commandes aux clients ?
4. Quelle est la clé permettant de relier les commandes aux produits ?
5. Quelle transformation avez-vous utilisée pour calculer le chiffre d'affaires ?
6. Quelle transformation avez-vous utilisée pour calculer le CA par ville ?
7. Quelle est la différence entre une transformation et une action de workflow ?
8. Quels sont les avantages d'utiliser Apache Hop plutôt qu'un script Python unique pour orchestrer ce traitement ?

12 Architecture attendue


À la fin du TD, votre projet devrait avoir une organisation similaire à :

```
ecommerce_td/  
|  
+-- data/  
| +-- clients.csv  
| +-- produits.csv  
| +-- commandes.csv  
|  
+-- pipelines/  
| +-- nettoyage.hpl  
| +-- jointure_ca.hpl  
| +-- ca_client.hpl  
| +-- ca_produit.hpl  
| +-- ca_ville.hpl  
|  
+-- workflows/  
| +-- traitement_complet.hwf  
|  
+-- output/  
    +-- resultats_ca_client.csv  
    +-- resultats_ca_produit.csv  
    +-- resultats_ca_ville.csv
```

Cette architecture n'est qu'une proposition. Vous pouvez choisir une organisation différente si vous pouvez la justifier.

13 Schéma global du traitement

Le traitement final doit conceptuellement ressembler à :



14 Critères de réussite

Le TD est considéré comme réussi si vous êtes capables de :

- créer un projet Apache Hop ;
- créer et exécuter un Pipeline ;
- importer des fichiers CSV ;
- inspecter les données ;
- filtrer les données invalides ;
- nettoyer les données ;
- effectuer des jointures ;
- créer une nouvelle colonne calculée ;
- effectuer une agrégation avec **Group By** ;
- exporter les résultats ;
- créer un Workflow ;
- enchaîner plusieurs traitements ;
- interpréter les logs en cas d'erreur.

Objectif

À la fin de l'exercice, vous devez être capables d'expliquer le chemin complet d'une donnée :

CSV brut → Nettoyage → Jointure → Transformation → Agrégation → Résultat

et de distinguer clairement la transformation des données réalisée par un **Pipeline** de l'orchestration réalisée par un **Workflow**.